# 图像压缩

## 黑白图像存储

像素点灰度值:0~255,为8位二进制数

图像的<mark>灰度值序列</mark>:{ $p_1, p_2, \ldots, p_n$ },  $p_i$ 为第i个像素点灰度值

图像存储:每个像素的灰度值占8位, 总计空间为 8n





# 图像变位压缩的概念

变位压缩存储: 将 $\{p_1, p_2, ..., p_n\}$ 分成 m 段  $S_1, S_2, ..., S_m$ 

同一段的像素占用位数相同第t段有l[t]个像素,每个占用b[t]位段头:记录l[t](8位)和b[t](3位)需要11位总位数为 $b[1]\cdot l[1]+b[2]\cdot l[2]+...+b[m]\cdot l[m]+11m$ 

# 图像压缩问题

约束条件: 第 t 段像素个数  $l[t] \le 256$  第 t 段占用空间:  $b[t] \times l[t] + 11$ 

$$b[t] = \left\lceil \log(\max_{p_k \in S_t} p_k + 1) \right\rceil \leq 8$$

问题: 给定像素序列{ $p_1, p_2, ..., p_n$ },确定最优分段,即

$$\min_{T} \{ \sum_{t=1}^{m} (b[t] \times l[t] + 11) \},$$

$$T = \{ S_{1}, S_{2}, ..., S_{m} \}$$
 为分段

# 实例

```
灰度值序列
```

分法1: 
$$S_1 = \{10, 12, 15\}$$
,  $S_2 = \{255\}$ ,  $S_3 = \{1, 2, 1, 1, 2, 2, 1, 1\}$ 

分法2: 
$$S_1$$
={10,12,15,255,1,2,1,1,2,2,1,1}

分法3: 分成12组,每组一个数

#### 存储空间

# 子问题界定与计算顺序

子问题前边界为1,后边界为i对应像素序列为 $< p_1, p_2, ..., p_i>$ 优化函数值S[i]为最优分段存贮位数计算顺序

$$i = 1$$
 $i = 2$ 
...

$$i = n$$

# 算法设计

递推方程: 设S[i]是 $\{p_1, p_2, \dots, p_i\}$  的最优分段需要的存储位数, $S_m$ 是最后分段

$$S[i] = \min_{1 \le j \le \min\{i, 256\}} \{ S[i-j] + j \times b[i-j+1,i] \} + 11$$

$$b[i-j+1,i] = \begin{bmatrix} \log(\max_{p_k \in S_m} p_k + 1) \end{bmatrix} \le 8$$

$$p_1 \quad p_2 \quad \dots \quad p_{i-j} \quad p_{i-j+1} \quad \dots \quad p_i$$

$$S[i-j] \land \dot{\Box} \qquad \qquad j \wedge \dot{E}$$

$$j \times b[i-j+1,i] \dot{\Box}$$

#### Compress (P,n)

# 伪码

子问题后

边界i

- 1.  $Lmax \leftarrow 256$ ;  $header \leftarrow 11$ ;  $S[0] \leftarrow 0$
- 2. for  $i \leftarrow 1$  to n do
- 3.  $b[i] \leftarrow length(P[i])$
- 4.  $bmax \leftarrow b[i]$
- 5.  $S[i] \leftarrow S[i-1] + bmax$
- 6.  $l[i] \leftarrow 1$
- 7. for  $j \leftarrow 2$  to min $\{i, Lmax\}$  do
- 8. if bmax < b[i-j+1]
- 9. then  $bmax \leftarrow b[i-j+1]$ 10. if S[i] > S[i-j] + j \*bmax
- 11. then  $S[i] \leftarrow S[i-j] + j *bmax$
- 12.  $l[i] \leftarrow j$
- 13.  $S[i] \leftarrow S[i] + header$

最后

段长j

$$P = <10, 12, 15, 255, 1, 2>.$$
  
 $S[1]=15, S[2]=19, S[3]=23, S[4]=42, S[5]=50$   
 $l[1]=1, l[2]=2, l[3]=3, l[4]=1, l[5]=2$ 

10	12	15	255	1	2	
S[5]=	=50			1×2-	<b>⊢11</b> 63	
10	12	15	255	1	2	
S[4]=42						
10	12	15	255	1	2	
S[3]=	23			$3\times8+11$ 58		
10	12	15	255	1	2	
S[2]=19			$4\times8+11$ 62			
10	12	15	255	1	2	
S[1]=15			5×8+11 66			
10	12	15	255	1	2	
$6 \times 8 + 11$					59	

# 追踪解

```
算法 Traceback (n, l)
```

输入:数组1

输出:数组C

1. j ← 1 // j 为正在追踪的段数

第j段

- 2. while  $n \neq 0$  do
- 3.  $C[j] \leftarrow l[n] \leftarrow kg$
- 4.  $n \leftarrow n l[n]$
- 5.  $j \leftarrow j + 1$

C[j]: 从后向前追踪的第j段的长度

时间复杂度: O(n)

## 小结

- 图像变位存储问题的建模
- 子问题边界的界定
- 递推方程及初值
- 伪码
- 标记函数与解的追踪
- 时间复杂度

# 最大子段和

## 最大子段和

问题: 给定n个数(可以为负数)的序列

$$(a_1, a_2, \dots, a_n)$$

求 
$$\max\{0, \max_{1 \le i \le j \le n} \sum_{k=i}^{j} a_k\}$$

#### 实例

$$(-2, 11, -4, 13, -5, -2)$$

解:最大子段和为  $a_2+a_3+a_4=20$ 

# 算法

算法1:对所有的(i,j)对,顺序求和

 $a_i + ... + a_j$  并比较出最大的和

算法2: 分治策略,将数组分成左右两半,分别计算左边的最大和、右边的最大和、跨边界的最大和,然后比较其中最大者

算法3: 动态规划

# 算法1

和的

边界*i-j* 

### 算法 Enumerate

输入:数组 A[1..n],

输出: sum, first, last

- 1.  $sum \leftarrow 0$
- 2. for  $i \leftarrow 1$  to n do
- 3. for  $j \leftarrow i$  to n do
- 4.  $thissum \leftarrow 0$
- 5. for  $k \leftarrow i$  to j do
- 6.  $thissum \leftarrow thissum + A[k]$
- 7. if thissum > sum
- 8. then  $sum \leftarrow thissum$
- 9.  $first \leftarrow i$
- 10.  $last \leftarrow j$

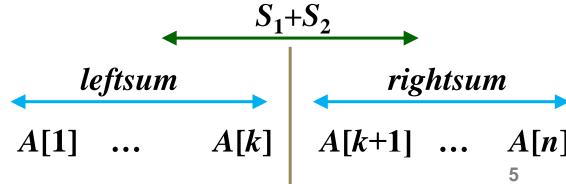
1

找到更

大和

# 算法2 分治策略

将序列分成左右两半,中间分点center 递归计算左段最大子段和 leftsum 递归计算右段最大子段和 rightsum center 到 $a_1$ 的最大和  $S_1$ , k=center center +1 到  $a_n$  的最大和  $S_2$ max { leftsum, rightsum,  $S_1$ + $S_2$  }



# 伪码

算法 MaxSubSum (A, left, right)

输入: 数组 A, left, right (左,右边界)

输出:最大子段和sum及子段边界

- 1. if |A|=1 then 输出元素(值为负输出0)
- 2.  $center \leftarrow \lfloor (left + right)/2 \rfloor$
- 3.  $leftsum \leftarrow \underline{MaxSubSum}(A, left,center)$
- 4.  $righsum \leftarrow MaxSubSum(A, center+1, right)$
- 5.  $S_1 \leftarrow A_1[center]$  //从center向左
- 6.  $S_2 \leftarrow A_2[center+1]$  //从center+1向右
- 7.  $sum \leftarrow S_1 + S_2$
- 8. if leftsum>sum then  $sum \leftarrow leftsum$
- 9. if rightsum>sum then sum←rightsum

# 时间复杂度

大和,每次加1个元素,得到 A[k], A[k]+A[k-1], A[k]+A[k-1]+A[k-2],..., A[k]+...+A[1]比较上述的最大和,时间为O(n), 右半边也是O(n)

$$T(n) = 2T(n/2) + O(n)$$

$$T(c) = O(1)$$

$$T(n) = O(n \log n)$$

# 算法3: 动态规划

子问题界定:前边界为 1,后边界 i, C[i] 是 A[1...i]中必须包含元素 A[i] 的 向前连续延伸的最大子段和

$$C[i] = \max_{1 \le k \le i} \left\{ \sum_{j=k}^{i} A[j] \right\}$$

# 优化函数的递推方程

```
递推方程:
C[i] = \max\{C[i-1] + A[i], A[i]\}
     i = 2, ..., n
C[1]=A[1] 若A[1]>0
          否则
C[1]=0
      OPT(A) = max\{C[i]\}
```

### 算法 MaxSum (A, n) 为码

输入:数组A

输出:最大子段和sum,子段最后位置c

- 1.  $sum \leftarrow 0$
- 2.  $b \leftarrow 0$
- 3. for  $i \leftarrow 1$  to n do
- 4. if b > 0
- 5. then  $b \leftarrow b + A[i]$
- 6. else  $b \leftarrow A[i]$
- 7. if b > sum
- 8. then  $sum \leftarrow b$
- 9.  $c \leftarrow i$
- 10. return sum, c

时间复杂度: O(n), 空间复杂度: O(n)

找到史 大的和

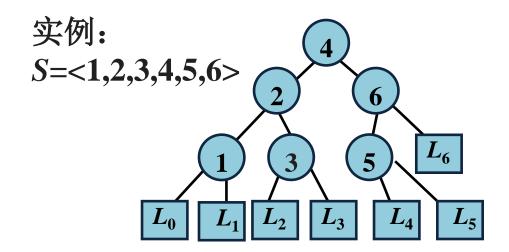
# 小结

- 几个算法: 蛮力,分治,动态规划
- 动态归划算法: 子问题界定 列优化函数的递推方程和边界条件 (不一定是原问题的优化函数) 自底向上计算,设计备忘录(表格) 如何根据动态规划的解找原问题的解 时间复杂度估计

# 最优二叉检索树

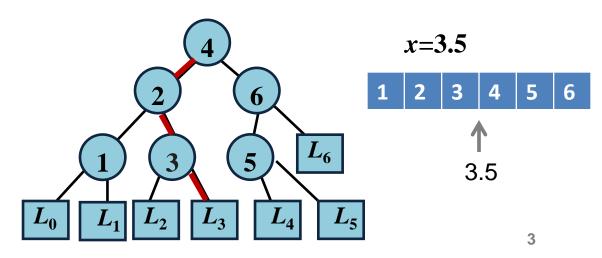
# 二叉检索树

集合S为排序的n个元素, $x_1 < x_2 < ... < x_n$ ,将这些元素存储在一棵二叉树的结点上,以查找x是否在这些数中.如果x不在,确定x在那个空隙(方结点).



### 二叉树的检索方法

- 1. 初始, x与根元素比较;
- 2. x < 根元素,递归进入左子树;
- 3. x > 根元素, 递归进入右子树;
- 4. x = 根元素, 算法停止, 输出 x;
- 5. x 到叶结点算法停止,输出 x不在数组.



# 数据元素存取概率分布

#### 空隙:

$$(x_0, x_1), (x_1, x_2), \dots, (x_{n-1}, x_n), (x_n, x_{n+1}),$$
  
 $x_0 = -\infty, x_{n+1} = +\infty$ 

给定序列 
$$S = \langle x_1, x_2, ..., x_n \rangle$$
,

x 在  $x_i$  的概率为 $b_i$ ,

x 在( $x_i$ ,  $x_{i+1}$ )的概率为 $a_i$ ,

#### S 的存取概率分布如下:

$$P = \langle a_0, b_1, a_1, b_2, a_2, \dots, b_n, a_n \rangle$$

# 实例

实例: 
$$S = \langle 1, 2, 3, 4, 5, 6 \rangle$$
  
 $P = \langle 0.04, 0.1, 0.01, 0.2, 0.05, 0.2, 0.02, 0.1, 0.02, 0.1, 0.07, 0.05, 0.04 \rangle$ 

- 1, 2, 3, 4, 5, 6 检索的概率分别为: 0.1, 0.2, 0.2, 0.1, 0.1, 0.05
- 各个空隙的检索概率分别为:
- 0.04, 0.01, 0.05, 0.02, 0.02, 0.07, 0.04

# 检索数据的平均时间

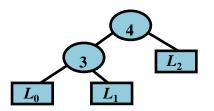
$$S = < 1, 2, 3, 4, 5, 6 >$$
 $P = < 0.04, 0.1, 0.01, 0.2, 0.05,$ 
 $0.2, 0.02, 0.1, 0.02, 0.1,$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.05, 0.04 >$ 
 $0.07, 0.05, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05, 0.05 >$ 
 $0.07, 0.05,$ 

# 检索数据的平均时间

$$S = < 1, 2, 3, 4, 5, 6 > P = < 0.04, 0.1, 0.01, 0.2, 0.05, 0.2, 0.02, 0.1, 0.05, 0.2, 0.04 > 0.04 > 0.04 > 0.04 > 0.04 > 0.04 > 0.04 > 0.05 + 0.04 + 0.05 + 0.02 + 0.04 > 0.05 + 0.02 + 0.05$$

# 平均比较次数计算

数据集  $S = \langle x_1, x_2, ..., x_n \rangle$  存取概率分布



$$P=\langle a_0,b_1,a_1,b_2,\ldots,a_i,b_{i+1},\ldots,b_n,a_n \rangle$$
 结点  $x_i$  在 $T$  中的深度是  $d(x_i)$ ,  $i=1,2,\ldots,n$ , 空隙  $L_j$  的深度为  $d(L_j)$ ,  $j=0,1,\ldots,n$ , 平均比较次数为:

$$t = \sum_{i=1}^{n} b_i (1 + d(x_i)) + \sum_{j=0}^{n} a_j d(L_j)$$

# 问题

#### 给定数据集

$$S = \langle x_1, x_2, ..., x_n \rangle,$$

及S的存取概率分布如下:

$$P = \langle a_0, b_1, a_1, b_2, a_2, \dots, b_n, a_n \rangle$$

求一棵最优的(即平均比较次数最少的)二分检索树.

# 小结

- 二叉检索树的构成
- 给定概率分布下,一棵二叉检索树 的平均检索时间估计
- 什么是最优二叉检索树

# 最优二叉检索 树的算法

# 关键问题

子问题边界界定 如何将该问题归结为更小的子问题 优化函数的递推方程及初值 计算顺序 是否需要标记函数 时间复杂度分析

# 子问题划分

子问题边界为(i,j) 数据集:  $S[i,j] = \langle x_i, x_{i+1}, \dots, x_j \rangle$ 存取概率分布:  $P[i,j] = \langle a_{i-1}, b_i, a_i, b_{i+1}, \dots, b_j, a_j \rangle$ 

输入实例: 
$$S = \langle A, \underline{B}, \underline{C}, \underline{D}, E \rangle$$
  
 $P = \langle 0.04, 0.1, 0.02, 0.3, 0.02, 0.1,$   
 $0.05, 0.2, 0.06, 0.1, 0.01 \rangle$ 

子问题:  $S[2,4] = \langle B, C, D \rangle$  $P[2,4] = \langle 0.02, 0.3, 0.02, 0.1, 0.05, 0.2, 0.06 \rangle$ 

### 子问题归约

以 $x_k$ 作为根归结为子问题: S[i, k-1], P[i, k-1]S[k+1,j], P[k+1,j] $S[1,5] = \langle A, B, C, D, E \rangle$  $P[1,5] = \langle 0.04, 0.1, 0.02, 0.3, 0.02, 0.1,$ 0.05, 0.2, 0.06, 0.1, 0.01>  $S[1,1] = \langle A \rangle$  $P[1,1] = \langle 0.04, 0.1, 0.02 \rangle$  $S[3,5] = \langle C,D,E \rangle$  $P[3,5] = \langle 0.02, 0.1, 0.05, 0.2, 0.06, 0.1, 0.01 \rangle$ 

# 子问题的概率之和

子问题界定 S[i,j] 和 P[i,j],令

$$w[i,j] = \sum_{p=i-1}^{j} a_p + \sum_{q=i}^{j} b_q$$

是P[i,j]中所有概率(数据与空隙)之和

实例: 
$$S[2,4]=\langle B,C,D\rangle$$

$$P[2,4]=\langle 0.02,0.3,0.02,0.1,0.05,0.2,0.06\rangle$$

$$w[2,4]=(0.3+0.1+0.2)$$

$$+(0.02+0.02+0.05+0.06)$$

$$= 0.75$$

### 优化函数的递推方程

设m[i,j]是相对于输入S[i,j]和P[i,j]的最优二叉搜索树的平均比较次数

#### 递推方程:

$$m[i,j] = \min_{i \le k \le j} \{ \underline{m[i,k-1]} + \underline{m[k+1,j]} + w[i,j] \},$$

$$1 \le i \le j \le n$$

$$m[i,i-1] = 0, \quad i = 1,2,..., n$$

# $m[i,j]_k$ 公式的证明

 $m[i,j]_k$ : 根为 $x_k$ 时平均比较次数的最小值  $m[i,j]_k$ 

作为子 树增加 次数

$$= (m[i,k-1] + w[i,k-1]) + (m[k+1,j] + w[k+1,j]) + 1 \times b_k$$

$$= (m[i,k-1] + m[k+1,j]) + (w[i,k-1] + b_k + w[k+1,j])$$

$$= (m[i,k-1] + m[k+1,j]) + (\sum_{p=i-1}^{k-1} a_p + \sum_{q=i}^{k-1} b_q) + b_k + (\sum_{p=k}^{j} a_p + \sum_{q=k+1}^{j} b_q)$$

$$= (m[i,k-1] + m[k+1,j]) + \sum_{p=i-1}^{j} a_p + \sum_{q=i}^{j} b_q$$

$$= m[i,k-1] + m[k+1,j] + w[i,j]$$

化简

# 递推方程 $m[i,j] = \min_{i \le k \le j} \{m[i,k-1] + m[k+1,j] + w[i,j]\},$

平均比较次数: 在所有k的情况下 $m[i,j]_k$ 的最小值

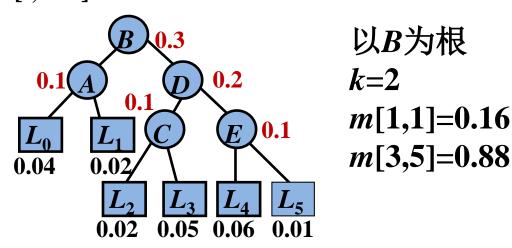
$$m[i,j] = \min\{ m[i,j]_k | i \le k \le j \}$$

初值 m[i, i-1]=0对应于空的子问题,例如  $S = \langle A, B, C, D, E \rangle$ ,取 A 作根,i=1,k=1,左边子问题为空树,对应于: S[1,0],m[1,0]=0的情况.

# 实例

$$m[i,j] = \min_{i \le k \le j} \{ m[i,k-1] + m[k+1,j] + w[i,j] \}$$

$$m[i,i-1]=0$$



$$m[1,5] = 1 + \min_{k=2,3,4} \{ m[1,k-1] + m[k+1,5] \}$$

$$=1+\{m[1,1]+m[3,5]\}=1+\{0.16+0.88\}=2.04$$

# 计算复杂性估计

$$m[i,j] = \min_{i \le k \le j} \{ m[i,k-1] + m[k+1,j] + w[i,j] \}$$

$$1 \le i \le j \le n$$

$$m[i,i-1] = 0, \quad i = 1,2,...,n$$

i,j的所有组合 $O(n^2)$ 种

每种要对不同的 k 进行计算,k=O(n)

每次计算为常数时间

时间复杂性:  $T(n) = O(n^3)$ 

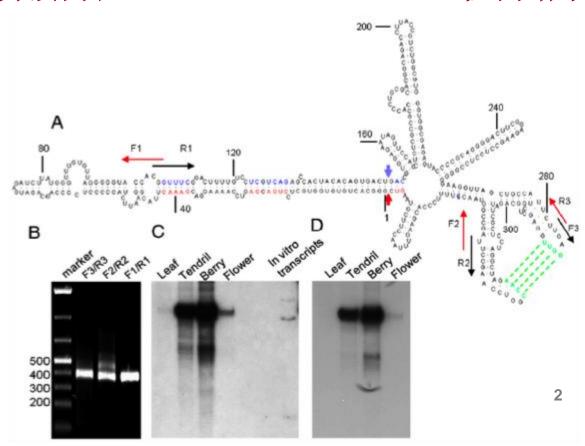
空间复杂度:  $S(n) = O(n^2)$ 

### 小结

- 划分子问题,以数据结点作为树根
- 定义优化函数,列出递推方程与边界条件
- 自底向上计算,设计备忘录(表格)
- 设立标记函数记录构成最优二叉搜索 树或子树时根的位置.
- 时间复杂度估计

# RNA二级结构预测

# 375nt 的环形类病毒GHVd 的 RNA二级结构预测和RT-PCR、Northern blot检测结果



# RNA二级结构

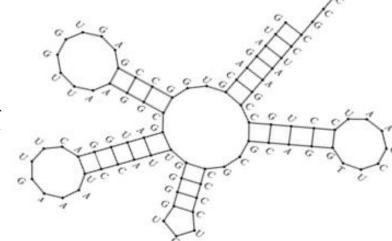
一级结构: 由字母A, C, G, U 标记的核苷酸构成的一条链.

实例: A-C-C-G-C-C-U-A-A-G-C-C-G-

*U-C-C-U-A-A-G-* ...

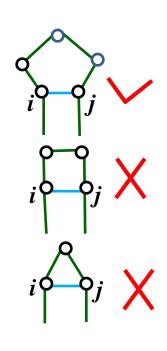
#### 二级结构:

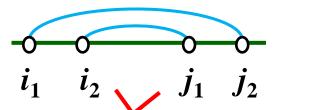
核苷酸相互 匹配构成的 平面结构



# 匹配原则

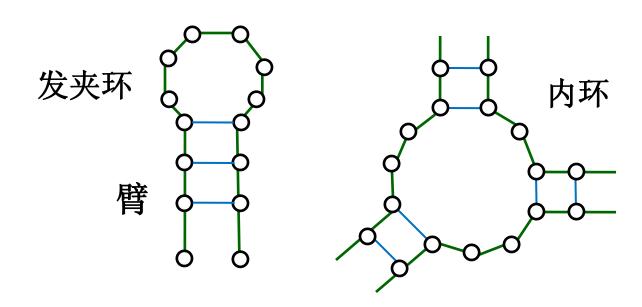
- 配对 *U-A*, *C-G*
- 末端不出现"尖角", 位置 i-j 配对, 则  $i \le j$ -4
- 每个核苷酸只能参加一个配对
- 不允许交叉,即如果位置  $i_1$ ,  $i_2$ ,  $j_1$ ,  $j_2$  满足  $i_1 < i_2 < j_1 < j_2$ ,不允许  $i_1 j_1$ ,  $i_2 j_2$  配对,但可以允许  $i_1 j_2$ ,  $i_2 j_1$  配对.







# 匹配的结构



#### RNA二级结构问题

给定RNA的一条链(一级结构),预测 它的可能的稳定的二级结构

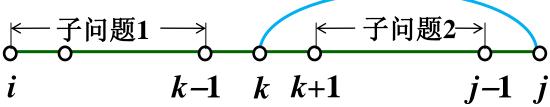
稳定二级结构满足的条件 生物学条件:具有最小自由能 简化条件:具有最多的匹配对数

问题:给定RNA链,求具有最多匹配对数的二级结构,即最优结构.

# 建模

- 子问题界定: 前边界i, 后边界j
- 若 *j*与*k* (所有可能)位置匹配,归约为 子问题 1: *i* 到 *k*-1的链

子问题 2: k+1到 j-1的链



• 若j不参与匹配,则原问题归约为i到j-1 的子问题

# 优化函数的递推方程

令C[i,j]是序列S[i..j]的最大匹配对数

$$C[i,j] = \max\{C[i,j-1],$$

$$\max_{i \le k \le j-4} \{1 + C[i,k-1] + C[k+1,j-1]\}\}$$

$$1 \le i, \quad j \le n, \quad j-i \ge 4$$

$$C[i,j] = 0 \quad j-i < 4$$

满足优化原则

计算顺序:按照子问题长度计算

# 计算复杂度分析

子问题个数: i,j 对的组合有  $O(n^2)$  个

对于给定的 i 和 j , j 需要考察与所有可能的 k 是否匹配,其中  $i \le k \le j - 4$ ,需要 O(n) 时间.

算法时间复杂度是  $O(n^3)$ .

### 小结

- 划分子问题,确定子问题边界*i*, *j* 与归约方法.
- 定义优化函数,列递推方程和初值.
- 自底向上计算,设计备忘录(表格)
- 设立标记函数,记下最优划分位置
- 时间复杂度估计

# 序列比对

# 序列比对

为确定两个序列之间的相似性或同源性,将它们按照一定的规律排列,进行比对.

#### • 应用:

生物信息学中用于研究同源性,如蛋白质序列或 DNA 序列. 在比对中, 错配与突变相对应,空位与插入或缺失相对应.

计算语言学中用于语言进化或文本相似性的研究.

# 序列之间的编辑距离

#### 编辑距离:

给定两个序列  $S_1$ 和  $S_2$ ,通过一系列字符编辑(插入、删除、替换)等操作,将 $S_1$ 转变成  $S_2$ .

完成这种转换所需要的最少的编辑操作个数称为 $S_1$ 和 $S_2$ 的编辑距离.

# 实例

vintner 转变成 writers, 编辑距离≤6

vintner

删除 v: -intner

插入w: wintner

插入r: wrintner

删除 n: wri-tner

删除 n: writ-er

插入s: writers

### 子问题界定和归约

 $S_1[1..n]$  和  $S_2[1..m]$  表示两个序列 子问题:  $S_1[1..i]$  和  $S_2[1..j]$ ,边界(i,j)

操作	归约子问题	编辑距离
删除S <sub>1</sub> [i]	(i-1,j)	+1
$S_1[i]$ 后插入 $S_2[j]$	( <i>i</i> , <i>j</i> -1)	+1
$S_1[i]$ 替换为 $S_2[j]$	(i-1, j-1)	+1
$S_1[i]=S_2[j]$	(i-1, j-1)	+0

# 优化函数的递推方程

C[i,j]:  $S_1[1..i]$  和  $S_2[1..j]$  的编辑距离

$$C[i,j] = \min\{C[i-1,j]+1,C[i,j-1]+1,$$

$$C[i-1,j-1]+t[i,j]\}$$

$$t[i,j] = \begin{cases} 0 & S_1[i] = S_2[j] \\ 1 & S_1[i] \neq S_2[j] \end{cases}$$

$$C[0,j] = j,$$

$$C[i,0] = i$$

# 计算复杂度分析

- 子问题 由 *i*, *j*界定, 有 *O* (*m n*) 个子问题
- 每个子问题的计算 为常数时间
- 算法的时间复杂度是O(n m)

# 动态规划算法设计要点

- (1) 引入参数来界定子问题的边界.注意子问题的重叠程度.
- (2) 给出带边界参数的优化函数定义与优化函数的递推关系,找到递推关系的初值.
- (3) 判断该优化问题是否满足优化原则.
- (4) 考虑是否需要标记函数.

# 动态规划算法设计要点(续)

- (5) 采用自底向上的实现技术,从最小的 子问题开始迭代计算,计算中用备忘 录保留优化函数和标记函数的值.
- (6) 动态规划算法的时间复杂度是对所有 子问题(备忘录)的计算工作量求和(可 能需要追踪解的工作量)
- (7) 动态规划算法一般使用较多的存储空间,这往往成为限制动态规划算法使用的瓶颈因素.